

● LEZIONE 02

I Dataset

dove trovarli, come leggerli e perché contano

● DEFINIZIONE

Cos'è un **dataset**



Una collezione organizzata

Un dataset è un insieme di dati raccolti e **organizzati** in una tabella: righe e colonne, come un foglio di calcolo.

Righe e colonne



Ogni riga è un' **osservazione** (una persona, un evento, un prodotto). Ogni colonna è una **caratteristica** misurata.



Ogni cella ha un valore

All'incrocio tra riga e colonna c'è un singolo **dato**: un numero, un testo, una data, un sì/no.

Nome	Età	Città	Voto
Marco	16	Roma	7.5
Sara	17	Milano	8.0
Luca	16	Napoli	6.5
Giulia	17	Roma	9.0

● STRUTTURA

Anatomia di un dataset



Osservazione (riga)

Ogni riga dopo l'header è un **record**: un individuo, un evento, una misurazione. Una riga = un "caso".



Variabile (colonna)

Ogni colonna misura una **caratteristica** di ciascuna osservazione.

Nome · Età · Città · Voto

1. Marco · 16 · Roma · 7.5

2. Sara · 17 · Milano · 8.0

Luca · 16 · Napoli · 6.5

ogni riga è un "caso", ogni colonna una misura

● ESEMPIO

Il registro della classe



Già lo conoscete

Il registro di classe è un dataset: ogni riga è uno studente, ogni colonna una materia o un'informazione.



Riconoscete le colonne?

Nome (*testuale*), data di nascita (*temporale*), città (*categorico*), voto di matematica (*dimensionale*).

il registro di classe

○	Marco 16 Roma 7.5
○	Sara 17 Milano 8.0
○	Luca 16 Napoli 6.5
○	Giulia 17 Roma 9.0
○	...

25 studenti = 25 righe!

● STRUTTURA

Ogni colonna ha un tipo



Riconoscerli è fondamentale

Il tipo di dato di ogni colonna determina quali operazioni puoi fare: media? conteggio? ordinamento? mappa?



Nello stesso dataset

Un dataset ha quasi sempre colonne di tipi diversi: testo, numeri, date, categorie. Mescolati nella stessa tabella.



Esercizio mentale

Guardate un dataset e per ogni colonna chiedetevi: è dimensionale? categorico? temporale? È il primo passo dell'analisi.

Nome <i>testuale</i>	Età <i>dimensionale</i>	Città <i>categorico</i>	Voto <i>dimensionale</i>
Marco	16	Roma	7.5
Sara	17	Milano	8.0
Luca	16	Napoli	6.5

tipi diversi, stessa tabella!

● DA DOVE VENGONO

Open Data



Dati aperti e gratuiti

Gli Open Data sono **dataset** pubblicati da enti pubblici e istituzioni, accessibili a tutti e riutilizzabili liberamente.



Leggibili dalle macchine

Devono essere in un formato che i computer possono **elaborare** (CSV, JSON), non un PDF fotografato!



Perché esistono

Trasparenza, monitoraggio civico, ricerca. I dati pubblici sono di tutti e permettono a chiunque di fare analisi **indipendenti**.

le 3 regole

1. Accessibili

2. Machine readable

3. Riutilizzabili

● DOVE CERCARE

I portali Open Data

tutti gratis!

I dati pubblici si trovano su portali dedicati, organizzati per livello territoriale. I dati comunali vengono raccolti nel catalogo regionale, poi nazionale, poi europeo.



data.europa.eu

Il catalogo europeo: milioni di dataset da tutti i paesi dell'UE.

europeo



dati.gov.it

Il portale nazionale italiano: dati dalla Pubblica Amministrazione.

nazionale

ISTAT



Portali regionali

Ogni regione e molti comuni pubblicano i propri dati aperti.

regionale

comunale



Zenodo e GitHub

Dati di ricerca scientifica e dataset condivisi dalla community.

ricerca

community

● QUALITÀ

Come valutare un dataset



Completezza

Ci sono valori mancanti? Quante celle sono vuote? Un dataset pieno di buchi è difficile da usare.



Aggiornamento

I dati sono recenti? Un dataset del 2010 potrebbe non raccontare più la realtà di oggi.



Formato e documentazione

È in un formato leggibile (CSV, Excel)? C'è una descrizione delle colonne? Senza documentazione, i dati sono muti.

checklist qualità

- ✓ Dati completi?
- ✓ Aggiornati?
- ✓ Formato aperto?
- ✓ Documentati?
- ~~✗~~ Licenza aperta?

controlla sempre!

● FORMATI

I formati dei dati

CSV (il più comune)

CSV

Comma Separated Values: un file di testo dove i valori sono separati da virgole. Semplice, leggero, universale.

JSON

JSON

Formato flessibile usato sul web. I dati sono organizzati in coppie chiave-valore, anche annidati.

Excel / Google Sheets



Fogli di calcolo con celle, formule e grafici integrati. È lo strumento che useremo nelle prossime lezioni.

lo stesso dato, 2 formati

CSV

```
nome,eta,citta,voto  
Marco,16,Roma,7.5  
Sara,17,Milano,8.0
```

stesso contenuto!

nome	eta	citta	voto
Marco	16	Roma	7.5
Sara	17	Milano	8.0

TABELLA

● LO STRUMENTO

Google Sheets



Cos'è

Un foglio di calcolo gratuito, online e collaborativo. Si apre dal browser, niente da installare.




Perché lo usiamo

Permette di importare dataset CSV, esplorare i dati, fare calcoli e creare grafici. Tutto in un unico strumento.



Setup iniziale

Impostare la lingua delle funzioni in inglese e il separatore decimale a punto (locale irlandese). Lo facciamo insieme!



● IN PRATICA

Il CSV da vicino

Comma Separated Values

CSV

Ogni riga del file è una riga della tabella. I valori sono separati da virgole. La prima riga è l' **header**.

Si apre con tutto



Un CSV si può aprire con un editor di testo, con Excel, con Google Sheets, con Python. È il formato più **portabile** che esista.

Attenzione al separatore



In Italia a volte si usa il **punto e virgola** (;) invece della virgola, perché la virgola è già il separatore decimale.

apri con un editor di testo

```
voti_classe.csv
nome,eta,citta,voto
Marco,16,Roma,7.5
Sara,17,Milano,8.0
Luca,16,Napoli,6.5
Giulia,17,Roma,9.0
```

head

le virgole separano i campi

semplice, no?

Il vostro dataset

Trovate un dataset su un tema che vi appassiona, esploratelo e presentatelo alla classe.

- 1 Cercate un dataset CSV su un portale Open Data, Kaggle o con una ricerca online su un tema a vostra scelta.
- 2 Scaricatelo, importatelo in Google Sheets e controllate che i dati siano leggibili.
- 3 Analizzatelo: quante righe, quante colonne, che tipo di dato ha ogni colonna, ci sono anomalie?
- 4 Preparate 3 frasi: perché avete scelto questo dataset, cosa contiene, cosa vi ha sorpreso o incuriosito.
- 5 Presentate alla classe il vostro dataset: raccontate i dati come se fosse una storia.

● RECAP

Cosa abbiamo **imparato** oggi

tutto chiaro?



Il dataset

Una tabella con righe (osservazioni) e colonne (variabili). Ogni cella è un dato.



Open Data

Dati pubblici, gratuiti e riutilizzabili. Si trovano su portali come dati.gov.it.



Il formato CSV

Testo semplice con virgole: il modo più universale per scambiare dati tabulari.



Google Sheets

Il nostro strumento: gratuito, nel browser, pronto per importare e esplorare dataset.