

pulizia!

● CAPITOLO 03

Pulire i Dati

perché i dati non arrivano mai perfetti

● IL PROBLEMA

Perché **pulire**



I dati non sono mai perfetti

Celle vuote, formati diversi, errori di battitura, valori impossibili. Ogni dataset del mondo reale ha dei problemi.




Garbage in, garbage out

Se analizzi dati sporchi, i risultati saranno sbagliati. La pulizia è il **primo passo** di ogni analisi seria.



Richiede tempo

I Data Scientist passano la maggior parte del tempo a pulire i dati, non ad analizzarli. È il lavoro meno glamour ma più importante.



● LE CAUSE

Da dove vengono gli errori



Errori di inserimento

Chi ha scritto i dati ha sbagliato: un refuso, un campo invertito, un numero con una cifra in più o in meno.



Formati incompatibili

Dati che arrivano da fonti diverse con formati diversi: date in ordini diversi, virgola vs punto, maiuscole vs minuscole.



Dati persi o incompleti

Il sensore si è spento, il campo è stato lasciato vuoto, il trasferimento ha perso delle righe. Succede più spesso di quanto si pensi.

un dataset "sporco"

Nome	Data	Valore
Marco	2024-03-15	7.5
Sara	15/03/2024	8,0
Luca	2024-03-15	???
Marco	2024-03-15	7.5
giulia	2024-03-15	999

dupli

5 problemi in 5 righe!

Le 4 fasi della **pulizia**

4 step!

Un processo ordinato per trasformare dati grezzi in dati utilizzabili.



1. Normalizzazione

Rendere tutti i dati coerenti nello stesso formato: date, unità, maiuscole.



2. Validazione

Controllare che i valori abbiano senso: età positive, voti nel range giusto.



3. Riempimento

Ricostruire i dati mancanti dove possibile: dedurre, stimare, documentare.



4. Rimozione

Eliminare ciò che non si può recuperare: duplicati, righe troppo incomplete, errori.

Dati grezzi → normalizzati → validati → riempiti → puliti. In quest'ordine.

● FASE 1

Normalizzazione

Rendere tutto coerente



Tutti i dati devono parlare la stessa lingua: stesso formato per le date, stessa unità di misura, stesse convenzioni per il testo.

Esempi comuni



"15/03/2024" vs "2024-03-15", "Roma" vs "roma" vs "ROMA", km vs miglia, virgola vs punto nei decimali.

Il principio



Scegli **un formato unico** e applicalo a tutto il dataset.
La coerenza viene prima della perfezione.

prima e dopo

Prima

15/03/2024

2024-03-16

March 17

ROMA

roma

Roma

caos!

Dopo

2024-03-15

2024-03-16

2024-03-17

Roma

Roma

Roma

ordine!

● FASE 2

Validazione

I valori hanno senso?



Un'età di -5 anni, un voto di 150 su 10, una temperatura di 900°C. Se un valore è **impossibile**, va segnalato e corretto.



Coerenza tra campi

Se la città è Roma, la regione non può essere Lombardia. I campi correlati devono essere coerenti tra loro.



Regole automatiche

Dove possibile, si definiscono regole: "l'età deve essere tra 0 e 120", "il voto tra 0 e 10". Tutto ciò che viola la regola viene evidenziato.

ha senso?

Età: 17 anni



Età: -5 anni



Voto: 8.5 / 10



Voto: 150 / 10



● FASE 3

Riempimento



Ricostruire i vuoti

Quando un dato manca, a volte si può ricostruire. Ma attenzione: non sempre è giusto farlo.



Come si fa

Dedurre : se la provincia è RM, la regione è Lazio.

Stimare : usare la media degli altri valori. Documentare sempre che il dato è stato ricostruito.



Quando non farlo

In contesti medici, legali o critici, inventare un dato mancante può essere **pericoloso** . Meglio lasciare vuoto e documentare.

riempire o lasciare vuoto?

Provincia: RM → Regione: ???
si deduce: Lazio ✓

Voto mancante, media classe: 7.2
si stima: ~7.2 (con cautela)

Diagnosi medica mancante
non si inventa! lascia vuoto ✗

● FASE 4

Rimozione

 **Duplicati**
Righe identiche o quasi identiche: lo stesso record inserito due volte. Si eliminano tenendo una sola copia.

 **Record troppo incompleti**
Se una riga ha troppe celle vuote, non è più utilizzabile. Meglio rimuoverla che inquinare l'analisi.

 **Outlier irrecuperabili**
Valori estremi che non possono essere né corretti né spiegati. Il 999 del sensore rotto, l'età di 300 anni. Se non ha senso, via.

cosa eliminare

Marco · 16 · Roma · 7.5

~~Marco · 16 · Roma · 7.5~~ ×

??? · ??? · ??? · 6.0 ×

Giulia · 300 · Roma · 999 ×

meno righe, ma più affidabili

● IN PRATICA

Prima e dopo

Prima della pulizia



5 righe con 5 problemi diversi: formato data diverso, decimale con virgola, valore mancante, duplicato, outlier, maiuscola sbagliata.

Dopo la pulizia



Date uniformi, decimali con il punto, valore stimato, duplicato rimosso, outlier rimosso, nomi capitalizzati. Da 5 righe sporche a 4 righe pulite.

Il messaggio



Meno righe ma dati affidabili. Un dataset pulito è più piccolo ma **infinitamente più utile** di uno grande e sporco.

Prima

Marco · 2024-03-15 · 7.5
Sara · 15/03/2024 · 8,0
Luca · 2024-03-15 · ???
Marco · 2024-03-15 · 7.5
giulia · 2024-03-15 · 999
5 righe, 5 problemi

pulizia!

Dopo

Marco · 2024-03-15 · 7.5 | Sara · 2024-03-15 · 8.0
Luca · 2024-03-15 · 7.2* | Giulia · 2024-03-15 · —
4 righe pulite, pronte per l'analisi

Pulisci il tuo dataset

Riprendete il dataset che avete scelto nel capitolo 2 e applicategli le 4 fasi della pulizia.

- 1 Normalizzate: i formati delle date sono tutti uguali? Le maiuscole sono coerenti?
- 2 Validate: ci sono valori impossibili o fuori range? Campi che non tornano tra loro?
- 3 Riempite: ci sono celle vuote che potete ricostruire? Documentate cosa avete fatto.
- 4 Rimuovete: ci sono duplicati? Righe troppo incomplete? Outlier senza spiegazione?
- 5 Confrontate il prima e il dopo: quante righe avete perso? Quanti problemi avete risolto?

● RECAP

Cosa abbiamo **imparato**

tutto chiaro?



Normalizzare

Rendere tutti i dati coerenti: un solo formato per date, unità e testo.



Validare

Controllare che i valori abbiano senso: range, coerenza, regole.



Riempire

Ricostruire i vuoti dove possibile, con cautela e documentando.



Rimuovere

Eliminare duplicati, record irrecuperabili e outlier senza senso.

Dati puliti = risultati affidabili. Garbage in, garbage out.